


TP15 - Outils d'optimisation en recherche

Plans d'expériences, Analyse en composantes principales (ACP)



Dans la recherche scientifique et l'ingénierie, de nombreux problèmes consistent à *optimiser* un système complexe : améliorer le rendement d'une réaction, ajuster la composition d'un matériau, stabiliser un médicament, concevoir un arôme, ou encore adapter un produit à un public donné. Dans ces situations, la réponse étudiée dépend rarement d'un seul paramètre. Plusieurs facteurs interviennent simultanément, et leurs effets peuvent se combiner de manière non évidente.

Les **plans d'expériences** permettent de construire une stratégie d'essais rationnelle. Au lieu de modifier les paramètres un par un, on choisit un ensemble limité d'expériences capable de fournir une information maximale sur le système. Ces méthodes sont très utilisées en chimie, en formulation, en agroalimentaire, en pharmacie, en science des matériaux, mais aussi dans des domaines éloignés de la chimie : par exemple, en ergonomie, on peut optimiser l'interface d'une application en étudiant l'influence de plusieurs choix de design sur la satisfaction des utilisateurs.

Dans ce TP, on s'intéressera à la **formulation d'une boisson**. Les variables étudiées ne seront pas des paramètres indépendants quelconques, mais les proportions de plusieurs constituants : on parlera alors de **plan de mélange**. L'objectif sera de produire différentes formulations, d'en évaluer les propriétés sensorielles, puis d'identifier les compositions les plus pertinentes selon les goûts recherchés.

Une fois les données obtenues, il faut encore les interpréter. Une formulation peut être décrite par plusieurs notes sensorielles : sucré, acide, fruité, floral, amer, rafraîchissant, équilibré, etc.

L'ensemble des résultats forme alors un jeu de données multidimensionnel, difficile à analyser directement. L'**analyse en composantes principales** permet de représenter ces données dans un espace plus simple, en conservant l'essentiel de l'information.

Elle servira ici à **cartographier les goûts** : rapprocher les boissons qui se ressemblent, repérer les formulations atypiques, mettre en évidence des directions sensorielles dominantes, et éventuellement identifier des groupes de préférences ou *clusters* correspondant à différentes cibles.

Votre mission


Vous avez à formuler une citronnade parfumée à la menthe répondant au mieux aux goûts des clients ciblés. Pour cela vous utiliserez différents outils d'optimisation et d'évaluation à l'aide du logiciel JMP :

- Planification des essais à l'aide d'un plan de mélange
- Estimation des réponses par analyse sensorielle
- Analyse statistique, cartographie des goûts dominants et identification des cibles par analyse en composantes principales (ACP).

1 La méthode des plans d'expérience : optimiser une ou plusieurs réponses

1.1 Pourquoi planifier les expériences ?

Lorsqu'on cherche à optimiser un système expérimental, une première idée consiste souvent à modifier un paramètre à la fois : on change la température en gardant tout le reste constant, puis on change la concentration, puis le temps de réaction, etc. Cette stratégie semble naturelle, mais elle devient rapidement inefficace dès que plusieurs facteurs interviennent simultanément.



Le problème vient du fait que les facteurs peuvent avoir des effets couplés. Par exemple, l'effet de la température sur un rendement chimique peut dépendre du pH ; l'effet d'un additif dans une formulation peut dépendre de la quantité d'eau ; l'effet d'un réglage machine peut dépendre de la vitesse de production. On parle alors d'**interaction** entre facteurs.

Un **plan d'expériences** consiste à choisir de façon raisonnée les essais à réaliser afin d'extraire un maximum d'information avec un nombre limité d'expériences. L'objectif n'est pas seulement de produire des données, mais de produire des données *interprétables* et utiles pour prendre une décision.

On distingue généralement :

- les **facteurs**, c'est-à-dire les variables que l'expérimentateur contrôle ;
- les **réponses**, c'est-à-dire les grandeurs mesurées que l'on cherche à expliquer ou à optimiser ;
- le **domaine expérimental**, c'est-à-dire l'ensemble des valeurs autorisées pour les facteurs ;
- le **modèle**, qui relie de manière approchée les facteurs aux réponses mesurées.

Par exemple, dans l'optimisation d'une synthèse, les facteurs peuvent être la température, la durée de chauffage et la quantité de catalyseur, tandis que les réponses peuvent être le rendement, la pureté du produit et la quantité de sous-produits formés. En dehors de la chimie, on peut citer l'exemple de l'agronomie : pour optimiser une culture, les facteurs peuvent être la quantité d'eau, la dose d'engrais et la densité de semis, tandis que les réponses peuvent être le rendement agricole, la teneur en protéines et la consommation d'eau.

1.2 Quelques grandes familles de plans

Il existe de nombreux types de plans d'expériences, adaptés à des objectifs différents.

- Les **plans factoriels** consistent à tester plusieurs facteurs à plusieurs niveaux. Les facteurs ne sont pas forcément numériques (ex : utilisation du catalyseur A ou du catalyseur B). Ils permettent d'étudier les effets principaux des facteurs et certaines interactions.
- Les **plans fractionnaires** permettent de réduire le nombre d'essais en ne réalisant qu'une partie bien choisie du plan factoriel complet.
- Les **plans de criblage** servent à repérer rapidement, parmi un grand nombre de facteurs, ceux qui semblent avoir un effet important sur la réponse. Ils sont souvent utilisés au début d'une étude.
- Les **plans de mélange** concernent les situations où les facteurs sont des proportions de constituants. C'est le cas lorsque l'on formule une boisson, un parfum, une colle, un matériau composite ou un médicament. La contrainte essentielle est alors que la somme des proportions vaut 1.

1.3 Modéliser une réponse expérimentale

Le principe mathématique général d'un plan d'expériences consiste à relier une réponse mesurée Y aux facteurs expérimentaux $x_1, x_2, \dots, x_p$. On cherche une relation approchée de la forme

$$Y = f(x_1, x_2, \dots, x_p) + \varepsilon,$$

où ε représente les erreurs de mesure, les fluctuations expérimentales et tout ce que le modèle ne décrit pas.

Dans beaucoup de situations, on commence par utiliser un modèle polynomial simple. Pour deux facteurs x_1 et x_2 , on peut par exemple écrire un modèle du premier degré avec interaction :

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \varepsilon.$$

Le coefficient β_1 traduit l'effet du facteur x_1 , le coefficient β_2 celui du facteur x_2 , et le coefficient β_{12} décrit l'interaction entre les deux facteurs. Si β_{12} est significatif, cela signifie que l'effet de x_1 dépend de la valeur de x_2 , et réciproquement.

Pour un modèle de surface de réponse, on peut introduire des termes quadratiques :

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{11} x_1^2 + \beta_{22} x_2^2 + \beta_{12} x_1 x_2 + \varepsilon.$$

Ces termes permettent de représenter une courbure de la réponse, et donc de localiser éventuellement un maximum, un minimum ou une zone de compromis.

1.4 Écriture matricielle du modèle

D'un point de vue mathématique, l'analyse d'un plan d'expériences repose sur l'algèbre linéaire. Supposons que l'on réalise n expériences et que l'on mesure une réponse Y pour chacune d'elles. Les résultats peuvent être regroupés dans un vecteur colonne :

$$\mathbf{y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}.$$

Le modèle peut alors s'écrire sous la forme matricielle :

$$\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}.$$

Dans cette écriture :

- $\mathbf{y}$ est le vecteur des réponses mesurées ;
- X est la **matrice du plan**, aussi appelée matrice de modèle ;
- $\boldsymbol{\beta}$ est le vecteur des coefficients inconnus du modèle ;
- $\boldsymbol{\varepsilon}$ est le vecteur des écarts entre le modèle et l'expérience.

Par exemple, pour un modèle

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_{12} x_1 x_2 + \varepsilon,$$

la matrice X contient une colonne de 1, une colonne avec les valeurs de x_1 , une colonne avec les valeurs de x_2 , et une colonne avec les produits $x_1 x_2$:

$$X = \begin{pmatrix} 1 & x_{1,1} & x_{2,1} & x_{1,1}x_{2,1} \\ 1 & x_{1,2} & x_{2,2} & x_{1,2}x_{2,2} \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_{1,n} & x_{2,n} & x_{1,n}x_{2,n} \end{pmatrix}.$$

L'estimation des coefficients se fait généralement par la méthode des moindres carrés. On cherche les coefficients β qui minimisent la somme des carrés des écarts entre les valeurs mesurées et les valeurs prévues par le modèle. Sous certaines conditions, l'estimateur s'écrit :

$$\hat{\beta} = (X^T X)^{-1} X^T \mathbf{y}.$$

Cette formule montre que le choix des expériences, donc la construction de la matrice X , est essentiel. Un bon plan d'expériences doit permettre d'estimer correctement les coefficients du modèle, de limiter les corrélations inutiles entre les effets et de rendre l'interprétation des résultats aussi fiable que possible.

1.5 Exemple : optimisation d'une colle à la caséine par un plan factoriel

L'objectif est d'étudier l'influence de plusieurs choix expérimentaux sur les propriétés finales de la colle. Dans ce cas on peut étudier :

- des **facteurs numériques**, comme une température, une durée ou une concentration ;
- des **facteurs qualitatifs**, comme la présence ou l'absence d'un additif, ou le choix entre deux matières premières.

On peut par exemple étudier les facteurs suivants :

Facteur	Niveau bas	Niveau haut
A : présence d'un épaississant	non	oui
B : matière première protéique	caséine commerciale	caséine extraite du lait
C : concentration en agent alcalin	2,0 %	5,0 %
D : température de préparation	25 °C	50 °C

Les facteurs A et B sont qualitatifs : ils ne correspondent pas à une grandeur mesurable continue, mais à un choix de formulation. Les facteurs C et D sont quantitatifs : ils peuvent prendre des valeurs numériques et être éventuellement étudiés plus finement par la suite.

Les réponses mesurées peuvent être, par exemple :

- Y_1 : la force d'adhésion après séchage ;
- Y_2 : la viscosité initiale ;
- Y_3 : le temps ouvert, c'est-à-dire la durée pendant laquelle la colle reste utilisable ;
- Y_4 : l'aspect du film formé après séchage ;
- Y_5 : la résistance à l'humidité.

Un plan factoriel complet à deux niveaux avec quatre facteurs demanderait :

$$2^4 = 16$$

expériences. Chaque expérience correspond à une combinaison particulière des niveaux bas et haut des quatre facteurs.

Pour traiter mathématiquement le plan, on code souvent les deux niveaux de chaque facteur par les valeurs -1 et $+1$:

$$\text{niveau bas} \longleftrightarrow -1, \quad \text{niveau haut} \longleftrightarrow +1.$$

Voici la matrice d'expériences correspondant à ce plan :

Expérience	A	B	C	D	Interprétation
1	-1	-1	-1	-1	sans épaississant, caséine commerciale, 2,0 %, 25 °C
2	+1	-1	-1	-1	avec épaississant, caséine commerciale, 2,0 %, 25 °C
3	-1	+1	-1	-1	sans épaississant, caséine extraite, 2,0 %, 25 °C
4	+1	+1	-1	-1	avec épaississant, caséine extraite, 2,0 %, 25 °C
5	-1	-1	+1	-1	sans épaississant, caséine commerciale, 5,0 %, 25 °C
6	+1	-1	+1	-1	avec épaississant, caséine commerciale, 5,0 %, 25 °C
7	-1	+1	+1	-1	sans épaississant, caséine extraite, 5,0 %, 25 °C
8	+1	+1	+1	-1	avec épaississant, caséine extraite, 5,0 %, 25 °C
9	-1	-1	-1	+1	sans épaississant, caséine commerciale, 2,0 %, 50 °C
10	+1	-1	-1	+1	avec épaississant, caséine commerciale, 2,0 %, 50 °C
11	-1	+1	-1	+1	sans épaississant, caséine extraite, 2,0 %, 50 °C
12	+1	+1	-1	+1	avec épaississant, caséine extraite, 2,0 %, 50 °C
13	-1	-1	+1	+1	sans épaississant, caséine commerciale, 5,0 %, 50 °C
14	+1	-1	+1	+1	avec épaississant, caséine commerciale, 5,0 %, 50 °C
15	-1	+1	+1	+1	sans épaississant, caséine extraite, 5,0 %, 50 °C
16	+1	+1	+1	+1	avec épaississant, caséine extraite, 5,0 %, 50 °C

Un tel plan permet d'étudier les effets principaux des facteurs, mais aussi certaines interactions. Par exemple, la présence d'un épaississant peut augmenter la viscosité. Mais cet effet peut dépendre de la nature de la caséine utilisée : l'épaississant peut être très efficace avec une caséine commerciale déjà purifiée, mais beaucoup moins avec une caséine extraite du lait, contenant encore d'autres constituants. Dans ce cas, il existe une interaction entre les facteurs A et B.

De même, l'effet de la concentration en agent alcalin peut dépendre de la température de préparation. Une concentration élevée peut améliorer la dispersion de la caséine à température

modérée, mais conduire à une dégradation ou à une modification excessive de la texture à température plus élevée. On aurait alors une interaction entre les facteurs C et D .

On peut alors proposer, pour une réponse Y , un modèle factoriel de la forme :

$$Y = \beta_0 + \beta_A A + \beta_B B + \beta_C C + \beta_D D + \beta_{AB} AB + \beta_{AC} AC + \beta_{AD} AD + \beta_{BC} BC + \beta_{BD} BD + \beta_{CD} CD + \varepsilon.$$

Dans ce modèle :

- β_0 représente la valeur moyenne de la réponse sur l'ensemble du plan ;
- $\beta_A, \beta_B, \beta_C$ et β_D représentent les effets principaux des facteurs ;
- les coefficients comme β_{AB} ou β_{CD} représentent des interactions entre deux facteurs ;
- ε représente l'écart entre les mesures expérimentales et les valeurs prédites par le modèle.

L'intérêt d'un tel modèle est de transformer une série d'expériences en informations interprétables. Par exemple :

- si β_A est positif pour la viscosité, la présence de l'épaississant augmente globalement la viscosité ;
- si β_A est négatif pour le temps ouvert, l'épaississant rend peut-être la colle plus difficile à utiliser longtemps ;
- si β_{AB} est important, l'effet de l'épaississant dépend fortement de la matière première protéique ;
- si β_{CD} est important, le rôle de l'agent alcalin dépend de la température de préparation.

On voit ainsi qu'un plan factoriel ne sert pas seulement à comparer des recettes. Il permet de comprendre quels facteurs contrôlent réellement les propriétés de la colle, et surtout de repérer les combinaisons favorables ou défavorables.

Dans une première étape, ce type de plan peut servir de **plan de criblage**. Il permet d'identifier les facteurs les plus influents parmi plusieurs choix possibles. Si l'on observe par exemple que la température de préparation a peu d'effet, mais que la nature de la caséine et la concentration en agent alcalin sont déterminantes, on pourra ensuite construire un plan plus fin uniquement sur ces facteurs.

L'optimisation peut alors être menée réponse par réponse, ou en recherchant un compromis : une colle intéressante doit présenter une force d'adhésion élevée, une viscosité suffisante mais pas excessive, un temps ouvert compatible avec l'utilisation, et un film final homogène. Le meilleur choix n'est donc pas nécessairement celui qui maximise une seule réponse, mais celui qui donne l'équilibre le plus satisfaisant entre plusieurs propriétés.

Cet exemple illustre la puissance des plans factoriels : ils permettent de traiter dans un même cadre des variables numériques et des choix qualitatifs, de mettre en évidence des interactions, et de passer d'une démarche empirique par essais successifs à une analyse structurée des effets expérimentaux.

2 Formulation de la citronnade à l'aide d'un plan de mélange

2.1 Construction du plan de mélange

L'objectif de cette partie est de formuler une citronnade expérimentale à partir de trois constituants actifs :

- une solution citronnée, notée x_1 ;
- un sirop de sucre de canne, noté x_2 ;
- une solution aqueuse d'arôme de menthe, notée x_3 .

La réponse mesurée sera une note d'appréciation globale, notée Y , comprise entre 0 et 100 :

$$0 \leq Y \leq 100.$$

Une note proche de 0 correspond à une boisson très peu appréciée, tandis qu'une note proche de 100 correspond à une boisson très appréciée.

Principe d'un plan de mélange

Dans un plan de mélange, les facteurs ne sont pas indépendants : ce sont des proportions relatives des différents constituants. On impose donc la contrainte :

$$x_1 + x_2 + x_3 = 1.$$

Ainsi, si l'on augmente la proportion d'un constituant, la proportion d'au moins un autre constituant doit nécessairement diminuer. Cette contrainte distingue les plans de mélanges des plans factoriels classiques.

Dans ce TP, l'eau n'est pas considérée comme un facteur du plan : elle est ajoutée en quantité constante afin de fixer la dilution globale de la boisson. On travaille donc sur une *phase active* constituée uniquement de citron, de sucre et de menthe.

Pour une boisson de volume final $V_f = 40$ mL, on choisit :

$$V_{\text{phase active}} = 10 \text{ mL}, \quad V_{\text{eau}} = 30 \text{ mL}.$$

Les volumes de citron, de sirop de sucre et de solution menthe sont donc calculés à partir des proportions x_1 , x_2 et x_3 selon :

$$V_i = x_i \times V_{\text{phase active}}.$$

Domaine expérimental retenu

Afin d'éviter des boissons trop extrêmes, par exemple trop acides, trop sucrées ou trop mentholées, on ne travaille pas sur le triangle complet des compositions possibles. On définit un domaine expérimental restreint par les niveaux suivants :

Constituant	Niveau bas	Niveau haut
x_1 citron	0,25	0,70
x_2 sucre	0,25	0,70
x_3 menthe	0,05	0,50

Ces contraintes définissent un triangle expérimental dont les trois sommets sont :

$$A = (0,70; 0,25; 0,05),$$

$$B = (0,25; 0,70; 0,05),$$

$$C = (0,25; 0,25; 0,50).$$

Le sommet A correspond à une boisson plutôt citronnée, le sommet B à une boisson plutôt sucrée, et le sommet C à une boisson fortement mentholée.

Choix du type de plan

Pour modéliser l'évolution de la note d'appréciation Y en fonction des proportions des constituants, on peut utiliser un modèle de mélange, avec un nombre plus ou moins grand de points :

- Modèle linéaire : $\hat{Y} = \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$. Ce modèle ne nécessite que 3 mélanges mais ne permet pas d'étudier les interactions.
- Modèle quadratique : $\hat{Y} = \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_{12} x_1 x_2 + \beta_{13} x_1 x_3 + \beta_{23} x_2 x_3$. Ce plan nécessite 7 mélanges. Les termes $x_i x_j$ traduisent les interactions de mélange : deux constituants peuvent donner ensemble une boisson plus appréciée, ou au contraire moins appréciée.
- Modèle cubique spécial : $\hat{Y} = \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_{12} x_1 x_2 + \beta_{13} x_1 x_3 + \beta_{23} x_2 x_3 + \beta_{123} x_1 x_2 x_3$. Le terme $x_1 x_2 x_3$ permet de prendre en compte un éventuel effet spécifique lorsque les trois constituants sont simultanément présents (cas rare).

Dans ce TP, on choisit un plan de type **simplex-centroïde** à 7 expériences qui permettra d'ajuster un modèle quadratique :

Matrice d'expériences

La matrice d'expériences retenue est la suivante. Les proportions sont données dans la phase active citron-sucre-menthe.

Mélange	x_1 citron	x_2 sucre	x_3 menthe	Nature du point
M_1	0,70	0,25	0,05	sommet citronné
M_2	0,25	0,70	0,05	sommet sucré
M_3	0,25	0,25	0,50	sommet mentholé
M_4	0,475	0,475	0,05	milieu $M_1 M_2$
M_5	0,475	0,25	0,275	milieu $M_1 M_3$
M_6	0,25	0,475	0,275	milieu $M_2 M_3$
M_7	0,40	0,40	0,20	centre du triangle
M_8	0,40	0,40	0,20	réplique de M_7
M_9	0,475	0,25	0,275	réplique de M_5

Pour limiter les biais et évaluer la fiabilité des évaluateurs on a recours à deux techniques :

- Randomisation : l'ordre de dégustation devra être randomisé et les échantillons devront être codés de manière anonyme. Les testeurs ne doivent pas être influencés par ce qu'ils estiment être la formule.
- Répliques : certains points peuvent être répétés pour vérifier que l'évaluateur met des notes similaires.

2.2 Création d'un plan de mélange avec JMP, visualisation du diagramme ternaire

JMP est un logiciel professionnel d'analyse statistique et de visualisation de données. Il est utilisé dans de nombreux domaines scientifiques et industriels, notamment pour l'analyse de données expérimentales, le contrôle qualité, l'optimisation de procédés et la construction de plans d'expériences.

Création du plan de mélange dans JMP

Dans JMP, créer un nouveau plan d'expériences de type *plan de mélange*.

1. Ouvrir JMP.
2. Dans le menu principal, choisir :

DOE → Plan de mélange

ou, selon la version :

Plans d'expériences → Plan de mélange.

3. Définir trois facteurs de mélange :

Citron, Sucre, Menthe.

4. Renseigner les niveaux bas et hauts de chaque facteur :

Facteur	Niveau bas	Niveau haut
Citron	0,25	0,70
Sucre	0,25	0,70
Menthe	0,05	0,50

5. Choisir le type de plan :

Plan de mélanges aux sommets extrêmes.

6. Choisir un plan de degré 3, de manière à obtenir :

- les trois sommets du triangle expérimental ;
- les trois milieux des arêtes ;
- le centre du triangle.

7. Cliquer sur :

Construire la table de données.

Le plan généré par JMP contient alors les sept formulations du plan simplex-centroïde dans le domaine contraint.

Matrice d'expériences obtenue

La matrice d'expériences doit être la suivante :

Mélange	x_1 Citron	x_2 Sucre	x_3 Menthe	Nature du point
M_1	0,700	0,250	0,050	sommet citronné
M_2	0,250	0,700	0,050	sommet sucré
M_3	0,250	0,250	0,500	sommet mentholé
M_4	0,475	0,475	0,050	milieu $M_1 M_2$
M_5	0,475	0,250	0,275	milieu $M_1 M_3$
M_6	0,250	0,475	0,275	milieu $M_2 M_3$
M_7	0,400	0,400	0,200	centre du triangle

On vérifie que, pour chaque ligne :

$$x_1 + x_2 + x_3 = 1.$$

Ajout de deux répliques

Afin d'évaluer la cohérence de la dégustation, deux formulations seront présentées deux fois sous des codes différents :

$$M_8 = M_5,$$

$$M_9 = M_7.$$

On obtient donc au total neuf échantillons dégustés, mais seulement sept formulations différentes.

La matrice complète des neuf échantillons est donc :

Échantillon	x_1 Citron	x_2 Sucre	x_3 Menthe	Remarque
M_1	0,700	0,250	0,050	formulation unique
M_2	0,250	0,700	0,050	formulation unique
M_3	0,250	0,250	0,500	formulation unique
M_4	0,475	0,475	0,050	formulation unique
M_5	0,475	0,250	0,275	formulation répliquée
M_6	0,250	0,475	0,275	formulation unique
M_7	0,400	0,400	0,200	formulation répliquée
M_8	0,475	0,250	0,275	réplique de M_5
M_9	0,400	0,400	0,200	réplique de M_7

Dans JMP, ces deux répliques peuvent être ajoutées directement dans la table de données en dupliquant les lignes correspondant à M_5 et M_7 .

Codage des échantillons pour la dégustation

Les dégustateurs ne doivent pas connaître la composition des échantillons. Les mélanges sont donc codés par des lettres de A à I.

On utilisera l'ordre de dégustation suivant :

Code dégustation	Mélange réel	x_1 Citron	x_2 Sucre	x_3 Menthe
A	M_4	0,475	0,475	0,050
B	M_2	0,250	0,700	0,050
C	M_1	0,700	0,250	0,050
D	M_7	0,400	0,400	0,200
E	M_6	0,250	0,475	0,275
F	M_5	0,475	0,250	0,275
G	$M_9 = M_7$	0,400	0,400	0,200
H	$M_8 = M_5$	0,475	0,250	0,275
I	M_3	0,250	0,250	0,500

Ce codage permet de garder l'expérience en aveugle. Les dégustateurs noteront les échantillons A à I sans connaître leur composition.

Visualisation du plan dans un diagramme ternaire

Pour visualiser les expériences dans le triangle des mélanges :

1. Dans la table de données JMP, sélectionner les colonnes :

Citron, Sucre, Menthe.

2. Dans le menu Graphique, choisir :

Diagramme ternaire

ou, selon la version de JMP :

Graphique $\longrightarrow$ Ternary Plot.

3. Associer les trois colonnes aux trois axes du diagramme ternaire.
4. Vérifier que les points expérimentaux appartiennent tous au triangle défini par les trois sommets :

$(0,70; 0,25; 0,05),$

$(0,25; 0,70; 0,05),$

$(0,25; 0,25; 0,50).$

Le diagramme ternaire permet de visualiser la géométrie du plan :

- les trois sommets correspondent aux formulations les plus typées ;
- les milieux des arêtes correspondent à des compromis entre deux sommets ;
- le centre correspond à une formulation équilibrée au sein du domaine choisi.

La zone explorée ne correspond pas au triangle complet des mélanges possibles, mais à un domaine restreint choisi pour obtenir des boissons dégustables tout en conservant des différences sensorielles marquées.

2.3 Traitement des données et modélisation des réponses

Objectif de l'analyse

L'objectif de cette partie est d'exploiter ces notes afin de construire un modèle reliant la note d'appréciation aux proportions des trois constituants actifs :

$$x_1 = \text{citron}, \quad x_2 = \text{sucres}, \quad x_3 = \text{menthe}.$$

On cherche donc à déterminer comment la formulation influence l'appréciation moyenne de la boisson.

Préparation de la table de résultats

Les réponses du formulaire sont d'abord exportées dans un tableur. Chaque ligne correspond à un évaluateur et chaque colonne A à I correspond à un échantillon dégusté.

Pour chaque échantillon, on calcule :

$$\bar{Y} = \text{note moyenne},$$

$$s_Y = \text{écart-type des notes},$$

Un écart-type élevé signifie que les évaluateurs ne sont pas tous d'accord sur l'appréciation de l'échantillon. Un écart-type faible signifie au contraire que les avis sont relativement homogènes.

On déterminera pendant la séance un critère d'élimination des testeurs incohérents afin d'obtenir des résultats plus fiables

La table à importer ou à construire dans JMP doit donc contenir les colonnes suivantes :

Colonne	Rôle
Code	code de dégustation A à I
Melange	mélange réel M_1 à M_9
Citron	proportion x_1
Sucres	proportion x_2
Menthe	proportion x_3
Note_moyenne	réponse moyenne $\bar{Y}$
Ecart_type	dispersion des notes

Dans la suite, la réponse modélisée est la note moyenne :

$$Y = \bar{Y}.$$

Analyse descriptive préalable

Avant de construire un modèle, il faut commencer par observer les données expérimentales.

Dans JMP, on peut représenter les notes moyennes des différents échantillons à l'aide d'un graphique en barres ou d'un tableau ordonné.

On cherchera à répondre aux questions suivantes :

- Quel échantillon obtient la meilleure note moyenne ?
- Quel échantillon obtient la moins bonne note moyenne ?
- Les différences de notes moyennes sont-elles importantes ?
- Les notes sont-elles très dispersées d'un évaluateur à l'autre ?

Dans JMP :

1. Ouvrir la table contenant les colonnes :

Code, Melange, Citron, Sucre, Menthe, Note, Ecart_Type.

2. Aller dans :

Graphique → Générateur de graphiques.

3. Placer la colonne Code sur l'axe horizontal.
4. Placer la colonne Note sur l'axe vertical.
5. Choisir une représentation par points.
6. Glisser les valeurs de la colonne Ecart_Type dans la case taille. La taille des points traduira alors la dispersion des valeurs.

Ce graphique permet de comparer rapidement les différents échantillons. Une note moyenne élevée indique un échantillon globalement apprécié. Un écart-type élevé indique au contraire que les avis sont dispersés : l'échantillon est alors plus clivant.

Interprétation du graphique

À partir du graphique des notes moyennes, on cherchera à répondre aux questions suivantes :

- Quel échantillon est le mieux noté en moyenne ?
- Quel échantillon est le moins bien noté en moyenne ?
- Les écarts entre les notes moyennes sont-ils importants ?
- Quels échantillons présentent les écarts-types les plus élevés ?
- Les répliques donnent-elles des résultats proches ?

Les répliques à comparer sont :

D et G ,

qui correspondent toutes deux au mélange central :

$$M_7 = (0,400; 0,400; 0,200),$$

et :

$$F \text{ et } H,$$

qui correspondent toutes deux au mélange :

$$M_5 = (0,475; 0,250; 0,275).$$

On calcule donc :

$$\Delta_{M_7} = |\bar{Y}_D - \bar{Y}_G|$$

et :

$$\Delta_{M_5} = |\bar{Y}_F - \bar{Y}_H|.$$

Des valeurs faibles de ces écarts indiquent que les dégustateurs ont noté de manière relativement cohérente deux échantillons identiques présentés sous deux codes différents.

Visualisation des notes dans le diagramme ternaire

On peut également représenter les réponses directement dans le triangle des mélanges.

Dans JMP :

1. Aller dans :

Graphique $\longrightarrow$ Diagramme ternaire.

2. Utiliser les colonnes :

Citron, Sucre, Menthe

comme coordonnées ternaires.

Pour colorer les points en fonction de la note :

1. Revenir à la table de données JMP contenant les colonnes :

Code, Melange, Citron, Sucre, Menthe, Note, Ecart_Type.

2. Dans le menu principal, choisir :

Lignes $\longrightarrow$ Couleur ou marque par colonne.

3. Dans la fenêtre qui s'ouvre, sélectionner la colonne :

Note.

4. Valider.

Les lignes de la table sont alors colorées selon la valeur de la note moyenne. Si le diagramme ternaire est déjà ouvert, les points du diagramme prennent automatiquement la même couleur que les lignes correspondantes.

Cette représentation est très utile car elle permet de repérer rapidement les zones du triangle correspondant aux formulations les plus appréciées.

Cette visualisation ne constitue pas encore une modélisation : elle permet simplement de repérer les grandes tendances avant l'ajustement du modèle de mélange.

Étude des répliques

Deux formulations sont présentées deux fois sous des codes différents :

$$M_8 = M_5, \quad M_9 = M_7.$$

Ces répliques permettent d'évaluer la cohérence des notes attribuées par les dégustateurs. On peut comparer les notes moyennes des deux couples de répliques :

$$\Delta_{M_5} = |\bar{Y}_{M_5} - \bar{Y}_{M_8}|,$$

$$\Delta_{M_7} = |\bar{Y}_{M_7} - \bar{Y}_{M_9}|.$$

Si ces écarts sont faibles, cela signifie que la notation est globalement cohérente. Si ces écarts sont élevés, plusieurs explications sont possibles :

- difficulté des évaluateurs à utiliser l'échelle de 0 à 100 ;
- effet de l'ordre de dégustation ;
- fatigue gustative ;
- influence d'un échantillon dégusté juste avant ;
- variabilité naturelle des préférences individuelles.

Dans le cadre de ce TP, ces répliques ne servent donc pas seulement à améliorer le modèle : elles permettent aussi de discuter la fiabilité des données sensorielles.

Choix du modèle de mélange

On impose ici un modèle quadratique :

$$\hat{Y} = \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_{12} x_1 x_2 + \beta_{13} x_1 x_3 + \beta_{23} x_2 x_3.$$

Les coefficients linéaires décrivent l'effet des trois pôles du triangle. Les termes quadratiques croisés décrivent les interactions de mélange.

Par exemple :

- un terme citron–sucre positif indique qu'une association citron/sucre est plus appréciée que ce que l'on prévoirait par simple interpolation entre les deux pôles ;

- un terme citron–menthe négatif peut indiquer que l'association acidité/menthe est moins appréciée ;
- un terme sucre–menthe positif peut indiquer que le sucre compense favorablement la puissance aromatique de la menthe.

Le modèle quadratique constitue ici un bon compromis : il est plus riche qu'un modèle linéaire, mais reste interprétable avec un nombre limité d'expériences.

Ajustement du modèle dans JMP

Dans JMP, l'ajustement du modèle se fait à partir de la table contenant les neuf échantillons codés.

1. Ouvrir la table de données contenant les colonnes :

Citron, Sucre, Menthe, Note_moyenne.

2. Dans le menu principal, choisir :

Analyse → Ajuster le modèle.

3. Placer la colonne Note_moyenne dans le rôle Y.
4. Placer les colonnes Citron, Sucre et Menthe comme facteurs explicatifs.
5. Construire le modèle quadratique de mélange en incluant les termes :

$x_1, x_2, x_3, x_1x_2, x_1x_3, x_2x_3.$

6. Lancer l'ajustement du modèle.

Le logiciel fournit alors une estimation des coefficients :

$\beta_1, \beta_2, \beta_3, \beta_{12}, \beta_{13}, \beta_{23}.$

On obtient donc une équation empirique de prédiction de la note :

$$\hat{Y} = f(x_1, x_2, x_3).$$

Qualité de l'ajustement

Après ajustement, il faut vérifier si le modèle décrit correctement les données.

On compare pour chaque échantillon :

$Y_{\text{observé}}$

et

$\hat{Y}_{\text{prédit}}.$

Le résidu associé à un échantillon est défini par :

$$e_i = Y_i - \hat{Y}_i.$$

Un résidu positif signifie que l'échantillon a été mieux noté que prévu par le modèle. Un résidu négatif signifie qu'il a été moins bien noté que prévu.

On pourra examiner :

- le graphique des valeurs observées en fonction des valeurs prédites;
- les résidus;
- le coefficient de détermination R^2 ;
- le coefficient de détermination ajusté $R^2_{\text{ajusté}}$;
- l'erreur quadratique moyenne ou RMSE.

Le coefficient R^2 mesure la part de la variabilité de la réponse expliquée par le modèle :

$$R^2 = 1 - \frac{\sum_i (Y_i - \hat{Y}_i)^2}{\sum_i (Y_i - \bar{Y})^2}.$$

Un R^2 proche de 1 indique que le modèle reproduit bien les données expérimentales. Il faut toutefois rester prudent : avec un petit nombre d'expériences, un bon R^2 ne suffit pas à garantir que le modèle est fiable pour prédire toute la zone du triangle.

Analyse de variance

L'analyse de variance permet d'évaluer si le modèle explique une part significative de la variabilité observée des notes.

L'idée générale est de décomposer la variabilité totale :

$$\sum_i (Y_i - \bar{Y})^2$$

en une part expliquée par le modèle et une part non expliquée, appelée variabilité résiduelle :

$$\sum_i (Y_i - \hat{Y}_i)^2.$$

JMP fournit une table d'analyse de variance contenant notamment :

- la somme des carrés expliquée par le modèle;
- la somme des carrés résiduelle;
- les degrés de liberté;
- une statistique de test;
- une valeur de probabilité, ou *p-value*.

Dans ce TP, on interprétera l'ANOVA de manière qualitative. On cherchera surtout à savoir :

- si le modèle quadratique décrit mieux les données qu'une simple moyenne ;
- quels termes semblent jouer un rôle important ;
- si certaines interactions de mélange paraissent favorables ou défavorables.

Il faut cependant garder à l'esprit que le nombre d'expériences est limité. Les conclusions statistiques doivent donc être considérées comme indicatives. L'objectif principal est de comprendre la démarche de modélisation et d'interpréter les tendances observées.

Travail à réaliser

1. À partir des réponses du formulaire, calculer pour chaque échantillon :

$$\bar{Y}, \quad s_Y, \quad n.$$

2. Construire dans JMP une table contenant les neuf échantillons codés, leurs compositions et leur note moyenne.
3. Comparer les notes moyennes des différents échantillons.
4. Comparer les deux couples de répliques :

$$M_5/M_8 \quad \text{et} \quad M_7/M_9.$$

5. Ajuster le modèle quadratique de mélange :

$$\hat{Y} = \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_{12} x_1 x_2 + \beta_{13} x_1 x_3 + \beta_{23} x_2 x_3.$$

6. Relever l'équation du modèle obtenu.
7. Étudier la qualité de l'ajustement : valeurs prédites, résidus, R^2 et $R^2_{\text{ajusté}}$.
8. Interpréter qualitativement les coefficients du modèle et l'analyse de variance.
9. Conclure sur les tendances principales :
 - influence du citron ;
 - influence du sucre ;
 - influence de la menthe ;
 - interactions favorables ou défavorables entre deux constituants.

Représentation du modèle dans le diagramme ternaire

Une fois le modèle quadratique ajusté, on ne se contente plus de représenter les notes expérimentales mesurées aux points du plan. On cherche maintenant à visualiser la réponse prédite par le modèle dans l'ensemble du domaine expérimental.

Le modèle ajusté fournit une fonction de prédiction :

$$\hat{Y} = \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_{12} x_1 x_2 + \beta_{13} x_1 x_3 + \beta_{23} x_2 x_3.$$

Cette fonction permet d'estimer la note moyenne attendue pour toute formulation du domaine, même si cette formulation n'a pas été préparée expérimentalement.

L'objectif est de représenter dans le diagramme ternaire :

- les points expérimentaux effectivement testés ;
- la note moyenne observée pour chaque point ;
- les valeurs prédites par le modèle ;
- les courbes d'isoréponse, c'est-à-dire les courbes correspondant à une même valeur de $\hat{Y}$.

Une courbe d'isoréponse est définie par une équation de la forme :

$$\hat{Y}(x_1, x_2, x_3) = Y_0,$$

où Y_0 est une valeur fixée de la note prédite.

Dans JMP, après l'ajustement du modèle :

1. Ouvrir la fenêtre de résultats du modèle ajusté.
2. Repérer les options graphiques associées au modèle, notamment les représentations de type :

Profileur, Contour Profiler, Graphique de contours

ou toute option équivalente selon la version utilisée.

3. Afficher la surface de réponse ou les courbes de niveaux dans le domaine défini par les trois proportions :

$$x_{\text{citron}}, \quad x_{\text{sucré}}, \quad x_{\text{menthe}}.$$

4. Vérifier que le domaine représenté correspond bien au triangle expérimental :

$$0,25 \leq x_{\text{citron}} \leq 0,70,$$

$$0,25 \leq x_{\text{sucré}} \leq 0,70,$$

$$0,05 \leq x_{\text{menthe}} \leq 0,50,$$

avec :

$$x_{\text{citron}} + x_{\text{sucré}} + x_{\text{menthe}} = 1.$$

5. Afficher, si possible, les points expérimentaux sur le même graphique que les courbes d'isoréponse.

Le diagramme obtenu permet de repérer les zones du triangle pour lesquelles la note prédite est élevée ou faible.

On interprète alors la carte de réponse en répondant aux questions suivantes :

- La meilleure zone se situe-t-elle près d'un sommet, d'une arête ou du centre du triangle ?
- La menthe semble-t-elle améliorer ou diminuer l'appréciation globale ?
- Le sucre compense-t-il l'acidité du citron ?
- Existe-t-il une zone de compromis où les trois constituants sont présents en proportions significatives ?
- Le meilleur point prédit par le modèle est-il proche d'un point réellement testé ?

Cette représentation graphique est importante, car elle permet de passer d'une simple comparaison des échantillons testés à une véritable analyse de formulation. Le modèle ne sert pas seulement à classer les boissons préparées : il permet de proposer de nouvelles formulations dans le domaine expérimental étudié.

Recherche d'une formulation optimale

L'étape suivante consiste à utiliser le modèle pour rechercher une formulation optimale, c'est-à-dire une formulation qui maximise la note d'appréciation prédite.

Mathématiquement, on cherche à résoudre le problème d'optimisation suivant :

$$\hat{Y}(x_1, x_2, x_3) \longrightarrow \max$$

sous les contraintes :

$$x_1 + x_2 + x_3 = 1,$$

$$0,25 \leq x_1 \leq 0,70,$$

$$0,25 \leq x_2 \leq 0,70,$$

$$0,05 \leq x_3 \leq 0,50.$$

Dans le cadre du TP, on note :

$$x_1 = x_{\text{citron}}, \quad x_2 = x_{\text{sucre}}, \quad x_3 = x_{\text{menthe}}.$$

L'optimum recherché est donc une composition :

$$(x_{\text{citron}}^*, x_{\text{sucre}}^*, x_{\text{menthe}}^*)$$

vérifiant les contraintes du domaine expérimental et conduisant à la valeur prédite maximale :

$$\hat{Y}_{\max} = \hat{Y}(x_{\text{citron}}^*, x_{\text{sucre}}^*, x_{\text{menthe}}^*).$$

Dans JMP, cette recherche peut se faire à partir du modèle ajusté :

1. Ouvrir la fenêtre de résultats du modèle.
2. Afficher le profileur de prédiction, ou l'outil d'optimisation associé au modèle.
3. Indiquer que la réponse Note doit être maximisée.
4. Laisser JMP rechercher la combinaison de facteurs donnant la note prédite la plus élevée.
5. Relever les proportions optimales proposées :

$$x_{\text{citron}}^*, \quad x_{\text{sucre}}^*, \quad x_{\text{menthe}}^*.$$

6. Vérifier que ces proportions appartiennent bien au domaine expérimental.

Il faut ensuite convertir ces proportions en volumes réellement prélevés. Dans ce TP, le volume de phase active est fixé à :

$$V_{\text{phase active}} = 10 \text{ mL}.$$

Les volumes optimaux sont donc :

$$V_{\text{citron}}^* = 10 x_{\text{citron}}^*,$$

$$V_{\text{sucre}}^* = 10 x_{\text{sucre}}^*,$$

$$V_{\text{menthe}}^* = 10 x_{\text{menthe}}^*.$$

Le volume d'eau reste constant :

$$V_{\text{eau}} = 30 \text{ mL}.$$

La formulation optimale prédite par le modèle est donc :

$$V_{\text{citron}}^* + V_{\text{sucre}}^* + V_{\text{menthe}}^* + 30 \text{ mL d'eau}.$$

Il est important de distinguer deux notions :

- le meilleur mélange effectivement testé ;
- le meilleur mélange prédit par le modèle.

Le meilleur mélange testé est celui qui possède la plus grande note moyenne expérimentale. Le meilleur mélange prédit peut être situé entre deux points expérimentaux. Il correspond alors à une formulation proposée par le modèle.

On discutera donc les points suivants :

- L'optimum prédit est-il proche d'un point déjà testé ?
- L'optimum se trouve-t-il à l'intérieur du triangle ou sur une arête ?
- Le modèle prédit-il une amélioration importante par rapport au meilleur point mesuré ?
- Cette formulation optimale est-elle réaliste du point de vue gustatif ?
- Serait-il nécessaire de préparer cette nouvelle formulation pour vérifier la prédiction du modèle ?

Cette dernière question est essentielle : un modèle statistique fournit une prédiction, mais cette prédiction doit idéalement être confirmée par une nouvelle expérience. Une formulation optimale obtenue par calcul n'est donc pas une conclusion définitive ; c'est une proposition expérimentale à tester.

Travail à réaliser

1. Afficher dans JMP la carte de réponse ou les courbes d'isoreponse associées au modèle quadratique.
2. Identifier sur le diagramme ternaire les zones où la note prédite est élevée.
3. Relever la formulation optimale proposée par JMP :

$$x_{\text{citron}}^*, \quad x_{\text{sucre}}^*, \quad x_{\text{menthe}}^*.$$

4. Convertir ces proportions en volumes pour une boisson de 40 mL.
5. Comparer cette formulation optimale au meilleur mélange réellement testé.
6. Discuter la fiabilité de cette optimisation en tenant compte :
 - du faible nombre de points expérimentaux ;
 - de la variabilité des notes ;
 - de la cohérence des répliques ;
 - du caractère subjectif de l'appréciation sensorielle.

3 Étude statistique des testeurs et cartographie des préférences

3.1 Objectifs de l'étude

Dans la partie précédente, on a étudié les mélanges du point de vue de la formulation : on a cherché à relier la note moyenne d'appréciation aux proportions de citron, de sucre et de menthe. Cette approche permet de déterminer une formulation globalement appréciée par l'ensemble des dégustateurs.

Cependant, une note moyenne peut masquer des préférences très différentes d'un dégustateur à l'autre. Deux boissons peuvent obtenir la même note moyenne tout en correspondant à des situations très différentes :

- tous les dégustateurs donnent une note moyenne proche ;
- certains dégustateurs adorent la boisson tandis que d'autres la rejettent.

Dans cette nouvelle partie, on ne cherche donc plus seulement à étudier les mélanges, mais les **profils de préférence des dégustateurs**. L'objectif est de répondre aux questions suivantes :

- Les dégustateurs ont-ils tous les mêmes préférences ?
- Certains dégustateurs présentent-ils des profils de notation proches ?
- Peut-on identifier des groupes de dégustateurs ?
- Ces groupes correspondent-ils à des préférences pour des formulations plus sucrées, plus citronnées ou plus mentholées ?
- La formulation optimale moyenne est-elle également optimale pour tous les dégustateurs ?

Cette étude correspond à une démarche de **cartographie des préférences**. Elle permet de passer d'une question globale :

Quelle est la meilleure citronnade en moyenne ?

à une question plus fine :

Quelles citronnades plaisent à quels types de dégustateurs ?

L'outil statistique principal utilisé dans cette partie sera l'analyse en composantes principales, ou ACP. L'ACP permettra de représenter les dégustateurs dans un espace de dimension réduite, généralement un plan, en fonction de leurs notes attribuées aux différents mélanges.

Chaque dégustateur sera donc considéré comme un individu statistique décrit par ses notes :

$$\mathbf{Y}_i = (Y_{i,M_1}, Y_{i,M_2}, \dots, Y_{i,M_7}),$$

où Y_{i,M_j} désigne la note attribuée par le dégustateur i au mélange M_j .

Deux dégustateurs proches sur la carte ACP auront des profils de notes proches. Deux dégustateurs éloignés auront au contraire des préférences différentes.

Cette partie permettra ainsi de montrer qu'une étude sensorielle ne se limite pas à la recherche d'un meilleur produit moyen. Elle peut aussi servir à identifier des **cibles de consommateurs** et à adapter une formulation à un type de préférence.

3.2 Préparation de la table des données individuelles

Les données utilisées dans cette partie proviennent du formulaire de notation rempli par les dégustateurs. Contrairement à l'analyse précédente, on ne travaille plus seulement avec les notes moyennes par mélange : on repart des **notes individuelles**.

La table brute issue du formulaire contient une ligne par dégustateur. Les colonnes A à I correspondent aux neuf échantillons codés dégustés.

Dégustateur	A	B	C	D	E	F	G	H	I
1	$Y_{1,A}$	$Y_{1,B}$	$Y_{1,C}$	$Y_{1,D}$	$Y_{1,E}$	$Y_{1,F}$	$Y_{1,G}$	$Y_{1,H}$	$Y_{1,I}$
2	$Y_{2,A}$	$Y_{2,B}$	$Y_{2,C}$	$Y_{2,D}$	$Y_{2,E}$	$Y_{2,F}$	$Y_{2,G}$	$Y_{2,H}$	$Y_{2,I}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	$Y_{n,A}$	$Y_{n,B}$	$Y_{n,C}$	$Y_{n,D}$	$Y_{n,E}$	$Y_{n,F}$	$Y_{n,G}$	$Y_{n,H}$	$Y_{n,I}$

Les codes A à I ne correspondent pas directement à l'ordre $M_1, M_2, \dots, M_9$ du plan de mélange. On rappelle la correspondance :

Code	Mélange réel	x_{citron}	$x_{\text{sucré}}$	x_{menthe}
A	M_4	0,475	0,475	0,050
B	M_2	0,250	0,700	0,050
C	M_1	0,700	0,250	0,050
D	M_7	0,400	0,400	0,200
E	M_6	0,250	0,475	0,275
F	M_5	0,475	0,250	0,275
G	$M_9 = M_7$	0,400	0,400	0,200
H	$M_8 = M_5$	0,475	0,250	0,275
I	M_3	0,250	0,250	0,500

Les échantillons D et G correspondent donc au même mélange :

$$D \equiv G \equiv M_7,$$

et les échantillons F et H correspondent également au même mélange :

$$F \equiv H \equiv M_5.$$

Ces duplications ont été introduites volontairement afin d'évaluer la cohérence des notations. Elles seront utilisées dans la suite pour contrôler la qualité des réponses.

Construction d'une table par formulation réelle

Pour l'analyse des préférences, il est préférable de travailler avec les sept formulations réelles du plan de mélange, et non avec les neuf codes de dégustation. En effet, si l'on gardait les neuf colonnes A à I comme variables actives, les mélanges M_5 et M_7 seraient pris en compte deux fois dans l'ACP. Ils auraient alors artificiellement plus de poids que les autres mélanges.

On remplace donc les deux couples de répliques par leur moyenne individuelle :

$$Y_{i,M_5} = \frac{Y_{i,F} + Y_{i,H}}{2},$$

$$Y_{i,M_7} = \frac{Y_{i,D} + Y_{i,G}}{2}.$$

Les autres mélanges sont simplement renommés selon la correspondance précédente :

$$Y_{i,M_1} = Y_{i,C},$$

$$Y_{i,M_2} = Y_{i,B},$$

$$Y_{i,M_3} = Y_{i,I},$$

$$Y_{i,M_4} = Y_{i,A},$$

$$Y_{i,M_6} = Y_{i,E}.$$

On obtient alors une nouvelle table, mieux adaptée à l'ACP :

Dégustateur	M_1	M_2	M_3	M_4	M_5	M_6	M_7
1	Y_{1,M_1}	Y_{1,M_2}	Y_{1,M_3}	Y_{1,M_4}	Y_{1,M_5}	Y_{1,M_6}	Y_{1,M_7}
2	Y_{2,M_1}	Y_{2,M_2}	Y_{2,M_3}	Y_{2,M_4}	Y_{2,M_5}	Y_{2,M_6}	Y_{2,M_7}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
n	Y_{n,M_1}	Y_{n,M_2}	Y_{n,M_3}	Y_{n,M_4}	Y_{n,M_5}	Y_{n,M_6}	Y_{n,M_7}

Chaque ligne représente maintenant un dégustateur, et chaque colonne représente une formulation réelle.

Ajout éventuel de variables descriptives

Le formulaire peut également contenir quelques informations complémentaires, par exemple :

- le profil du dégustateur : élève, enseignant, personnel, autre ;
- une tranche d'âge ;
- le goût déclaré pour les boissons sucrées ;
- le goût déclaré pour les boissons acides ou citronnées ;
- le goût déclaré pour la menthe.

Ces informations ne doivent pas servir à construire l'ACP principale. Les variables actives de l'ACP seront uniquement les notes données aux mélanges.

Les informations complémentaires seront utilisées comme variables illustratives : elles permettront de colorer les points ou d'interpréter les groupes de dégustateurs après coup.

La table finale destinée à l'ACP pourra donc avoir la structure suivante :

Dégustateur	M_1	M_2	M_3	M_4	M_5	M_6	M_7	Profil	Aime la menthe	Aime l'acide
1	...	...	...	...	...	...	...	...	...	...
2	...	...	...	...	...	...	...	...	...	...
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

Cette table sera la base de l'étude des préférences individuelles.

3.3 Visualisation exploratoire des préférences et réalisation d'un rapport

Avant de réaliser une analyse en composantes principales, il est utile d'explorer les données individuelles de manière graphique. Cette étape permet de repérer rapidement :

- les mélanges globalement appréciés ou rejetés ;
- les mélanges qui divisent fortement les dégustateurs ;
- les dégustateurs ayant des profils de notation particuliers ;
- les éventuelles structures de préférences avant toute analyse plus avancée.

Dans cette partie, on travaille avec la table finale contenant une ligne par dégustateur et une colonne par formulation réelle :

Dégustateur	M_1	M_2	M_3	M_4	M_5	M_6	M_7
E01	...	...	...	...	...	...	...
E02	...	...	...	...	...	...	...
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

Chaque ligne représente donc un profil de préférence.

Transformation de la table au format long

Pour réaliser facilement certains graphiques, on transforme la table initiale au format *long*. Au lieu d'avoir une colonne par mélange, on crée une table dans laquelle chaque ligne correspond à une note donnée par un dégustateur à un mélange.

La table initiale est de la forme :

Dégustateur	M_1	M_2	M_3	M_4	M_5	M_6	M_7
E01	42	88	18	82	35	58	76
E02	38	91	22	85	31	62	79

La table au format long devient :

Dégustateur	Mélange	Note
E01	M ₁	42
E01	M ₂	88
E01	M ₃	18
⋮	⋮	⋮
E02	M ₁	38
E02	M ₂	91

Dans JMP :

1. Ouvrir la table contenant les colonnes :

Évaluateur, M1, M2, ..., M7.

2. Aller dans :

Tables → Empiler

ou, selon la version :

Tables → Stack.

3. Sélectionner les colonnes :

M1, M2, ..., M7.

4. Conserver la colonne Évaluateur comme colonne d'identification.

5. Renommer les deux colonnes créées :

Mélange et Note.

Cette table au format long sera utilisée pour les graphiques de comparaison des mélanges.

Diagrammes en boîtes des notes par mélange

Le premier graphique utile est un diagramme en boîtes, ou *boxplot*, des notes attribuées à chaque mélange.

Dans JMP, à partir de la table au format long :

1. Aller dans :

Graphique → Générateur de graphiques.

2. Placer la colonne Mélange sur l'axe horizontal.

3. Placer la colonne Note sur l'axe vertical.

4. Choisir une représentation de type :

Boîte à moustaches

ou *boxplot*.

5. Afficher éventuellement les points individuels en plus des boîtes.

Ce graphique permet de visualiser la distribution des notes pour chaque formulation.

On interprète le graphique de la manière suivante :

- une boîte située haut indique un mélange globalement apprécié ;
- une boîte située bas indique un mélange globalement peu apprécié ;
- une boîte étendue indique un mélange qui divise les dégustateurs ;
- une boîte resserrée indique un accord plus fort entre les dégustateurs.

Profils individuels de dégustation

On peut ensuite représenter le profil de chaque dégustateur sous forme de courbe. Chaque courbe relie les notes données par un même dégustateur aux sept mélanges.

Dans JMP, à partir de la table au format long :

1. Aller dans :

Graphique → Générateur de graphiques.

2. Placer Mélange sur l'axe horizontal.
3. Placer Note sur l'axe vertical.
4. Utiliser Evalueur comme variable de groupement ou de superposition.
5. Choisir une représentation par lignes et points.

On obtient alors un ensemble de courbes individuelles. Ce graphique peut sembler chargé, mais il permet de voir si les dégustateurs ont des comportements similaires ou très différents.

Deux courbes proches correspondent à deux dégustateurs ayant des préférences voisines. Des courbes très différentes indiquent au contraire des profils de goût différents.

Carte de chaleur des notes

Une autre représentation très utile est la carte de chaleur, ou *heat map*. Elle représente les notes sous forme de couleurs.

Dans cette représentation :

- les lignes correspondent aux dégustateurs ;
- les colonnes correspondent aux mélanges ;
- la couleur correspond à la note attribuée.

Dans JMP, on peut construire ce type de graphique avec le Générateur de graphiques :

1. Utiliser la table au format long.
2. Aller dans :

Graphique → Générateur de graphiques.

3. Placer Mélange sur l'axe horizontal.
4. Placer Evalueur sur l'axe vertical.

5. Placer Note dans la zone de couleur.
6. Choisir un affichage de type carte de chaleur si l'option est disponible.

La carte de chaleur permet de repérer visuellement des groupes de dégustateurs : certains peuvent attribuer des notes élevées aux mélanges sucrés, d'autres aux mélanges mentholés, d'autres encore aux mélanges plus équilibrés.

Cette représentation prépare l'analyse en composantes principales, car elle montre déjà que chaque dégustateur peut être décrit par un profil de notes.

Matrice de corrélation entre mélanges

Avant de réaliser l'ACP, on peut également étudier les corrélations entre les notes attribuées aux différents mélanges.

Deux mélanges sont positivement corrélés si les dégustateurs qui apprécient l'un ont tendance à apprécier aussi l'autre. Ils sont négativement corrélés si les dégustateurs qui apprécient l'un ont tendance à rejeter l'autre.

Dans JMP, à partir de la table initiale au format large :

1. Aller dans :

Analyse → Méthodes multivariées → Multivarié.

2. Sélectionner les colonnes :

M1, M2, ..., M7.

3. Afficher la matrice de corrélation.

Cette matrice aide à identifier des familles de mélanges. Par exemple, si deux mélanges contenant beaucoup de menthe sont fortement corrélés, cela signifie qu'ils sont appréciés par des dégustateurs semblables.

Réalisation d'un rapport avec JMP

Les graphiques et tableaux obtenus peuvent être rassemblés dans un rapport JMP. Ce rapport permet de conserver les résultats de l'analyse et de les commenter.

Dans JMP, on peut procéder ainsi :

1. Pour chaque graphique ou tableau obtenu, vérifier qu'il est lisible :
 - titre explicite ;
 - axes correctement nommés ;
 - unités ou échelles indiquées ;
 - légende lisible.

2. Ajouter les résultats importants dans un journal JMP. Selon la version utilisée, on peut utiliser :

Fichier → Nouveau → Journal

puis copier-coller les graphiques dans ce journal.

3. On peut aussi utiliser le menu associé au graphique ou au rapport, souvent accessible par un triangle rouge, puis choisir une option du type :

Journal

ou

Ajouter au journal.

4. Dans le journal, ajouter de courts commentaires sous chaque graphique.

Le rapport devra contenir au minimum :

- le tableau des données utilisées ;
- le diagramme en boîtes des notes par mélange ;
- une représentation des profils individuels ou une carte de chaleur ;
- la matrice de corrélation entre mélanges ;
- quelques phrases d'interprétation.

Questions d'interprétation

À partir de ces visualisations, répondre aux questions suivantes :

1. Quels mélanges semblent globalement les plus appréciés ?
2. Quels mélanges semblent globalement les moins appréciés ?
3. Certains mélanges divisent-ils fortement les dégustateurs ?
4. Voit-on déjà apparaître des groupes de dégustateurs ?
5. Certains mélanges semblent-ils appréciés par les mêmes dégustateurs ?
6. Ces observations suggèrent-elles que la moyenne globale est suffisante pour décrire les préférences ?

Cette étape exploratoire prépare l'ACP. Elle permet de comprendre que les données ne contiennent pas seulement une information sur les mélanges, mais aussi sur les profils individuels des dégustateurs.

3.4 Analyse en composantes principales : cartographie des préférences individuelles

Principe général de l'ACP

L'analyse en composantes principales, ou ACP, est une méthode statistique qui permet de représenter simplement des données comportant plusieurs variables.

Dans notre cas, chaque dégustateur est décrit par les notes qu'il a attribuées aux sept formulations réelles du plan de mélange :

$$M_1, M_2, M_3, M_4, M_5, M_6, M_7.$$

Chaque dégustateur peut donc être représenté par un vecteur de notes :

$$\mathbf{Y}_i = (Y_{i,M_1}, Y_{i,M_2}, Y_{i,M_3}, Y_{i,M_4}, Y_{i,M_5}, Y_{i,M_6}, Y_{i,M_7}),$$

où Y_{i,M_j} désigne la note donnée par le dégustateur i au mélange M_j .

Chaque dégustateur est donc un point dans un espace à sept dimensions. Une telle représentation est impossible à visualiser directement. L'objectif de l'ACP est de construire de nouveaux axes, appelés **composantes principales**, qui résument le mieux possible les différences entre les dégustateurs.

La première composante principale, notée PC1, est l'axe qui explique la plus grande partie de la variabilité des profils de notation. La deuxième composante principale, notée PC2, explique la plus grande partie de la variabilité restante, sous la contrainte d'être orthogonale à PC1.

On cherche donc à projeter les dégustateurs dans un plan :

$$(PC1, PC2)$$

en conservant le maximum d'information.

L'interprétation est la suivante :

- deux dégustateurs proches sur la carte ACP ont donné des notes similaires aux différents mélanges ;
- deux dégustateurs éloignés ont des profils de préférence différents ;
- un groupe de dégustateurs proches peut correspondre à une famille de goûts ;
- les directions associées aux variables $M_1, \dots, M_7$ permettent de comprendre quels mélanges structurent les préférences.

L'ACP ne cherche donc pas directement la meilleure formulation moyenne. Elle cherche à comprendre la diversité des préférences individuelles.

Données utilisées pour l'ACP

Pour réaliser l'ACP, on utilise la table contenant une ligne par dégustateur et une colonne par formulation réelle :

Dégustateur	M_1	M_2	M_3	M_4	M_5	M_6	M_7
E01	Y_{1,M_1}	Y_{1,M_2}	Y_{1,M_3}	Y_{1,M_4}	Y_{1,M_5}	Y_{1,M_6}	Y_{1,M_7}
E02	Y_{2,M_1}	Y_{2,M_2}	Y_{2,M_3}	Y_{2,M_4}	Y_{2,M_5}	Y_{2,M_6}	Y_{2,M_7}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

On rappelle que les mélanges répliqués ont été moyennés pour ne pas donner artificiellement plus de poids à M_5 et M_7 :

$$Y_{i,M_5} = \frac{Y_{i,F} + Y_{i,H}}{2},$$

$$Y_{i,M_7} = \frac{Y_{i,D} + Y_{i,G}}{2}.$$

Les variables actives de l'ACP sont donc uniquement :

$$M_1, M_2, M_3, M_4, M_5, M_6, M_7.$$

Les éventuelles informations complémentaires sur les dégustateurs, comme l'âge, le profil ou le goût déclaré pour la menthe, ne doivent pas être utilisées comme variables actives de l'ACP. Elles pourront être utilisées ensuite pour colorer ou interpréter les points.

Réalisation de l'ACP dans JMP

Pour réaliser l'ACP dans JMP :

1. Ouvrir la table contenant une ligne par dégustateur.
2. Si les notes ont été normalisées, utiliser les colonnes :

$$M1_norm, M2_norm, \dots, M7_norm.$$

Sinon, utiliser directement les colonnes :

$$M1, M2, \dots, M7.$$

3. Aller dans :

Analyse → Méthodes multivariées → Composantes principales.

Selon la version de JMP, le menu peut également apparaître sous le nom :

Analyse → Multivarié → ACP.

4. Placer les sept variables de note dans la zone des variables actives.
5. Lancer l'analyse.
6. Afficher les résultats suivants :
 - valeurs propres ;
 - pourcentage de variance expliqué par chaque composante ;
 - graphique des individus ;
 - représentation des variables ;
 - biplot si disponible.

Choix du nombre d'axes à interpréter

JMP fournit un tableau indiquant la part de variance expliquée par chaque composante principale.

On note :

$$\lambda_1, \lambda_2, \dots, \lambda_7$$

les valeurs propres associées aux sept composantes principales.

La proportion de variance expliquée par l'axe k est :

$$p_k = \frac{\lambda_k}{\lambda_1 + \lambda_2 + \dots + \lambda_7}.$$

La proportion de variance expliquée par les deux premiers axes est donc :

$$p_1 + p_2.$$

Si les deux premiers axes expliquent une part importante de la variance, par exemple plus de 60 ou 70 %, le plan ACP donne une représentation assez satisfaisante des profils de préférence.

On pourra commenter :

- la part de variance expliquée par PC1 ;
- la part de variance expliquée par PC2 ;
- la part cumulée PC1 + PC2 ;
- l'intérêt éventuel d'observer un troisième axe si PC1 + PC2 explique peu de variance.

Interprétation du graphique des dégustateurs

Le graphique des individus représente les dégustateurs dans le plan :

$$(PC1, PC2).$$

Chaque point correspond à un dégustateur.

L'interprétation se fait de la manière suivante :

- deux points proches correspondent à deux dégustateurs ayant donné des notes semblables aux mélanges ;
- des points très éloignés correspondent à des profils de préférence différents ;
- un groupe de points proches peut correspondre à une famille de dégustateurs ;
- un point isolé peut correspondre à un dégustateur au profil particulier.

On cherchera à répondre aux questions suivantes :

1. Le nuage de points est-il homogène ou observe-t-on plusieurs groupes ?
2. Certains dégustateurs sont-ils isolés ?
3. Peut-on repérer un groupe d'amateurs de menthe ?
4. Peut-on repérer un groupe préférant les mélanges sucrés ou peu mentholés ?

Interprétation des variables

L'ACP permet également de représenter les variables, c'est-à-dire les mélanges $M_1, \dots, M_7$.

Les variables peuvent être vues comme des directions de préférence. Si un dégustateur est placé dans la direction d'un mélange donné, cela signifie qu'il a tendance à bien noter ce mélange.

Deux variables proches correspondent à deux mélanges appréciés par les mêmes dégustateurs. Deux variables opposées correspondent à deux mélanges qui plaisent à des dégustateurs différents.

On interprète donc les directions de la manière suivante :

- si M_3 est isolé dans une direction, cela peut indiquer que le mélange très mentholé plaît à un groupe particulier ;
- si M_2 et M_4 sont proches, cela signifie que les dégustateurs qui apprécient l'un apprécient souvent l'autre ;
- si M_3 est opposé à M_2 ou M_4 , cela peut indiquer une opposition entre amateurs de menthe forte et amateurs de citronnade plus classique.

L'objectif est de relier les axes de l'ACP aux caractéristiques sensorielles des mélanges :

sucré, citronné, mentholé, équilibré.

Utilisation du biplot

Le biplot représente simultanément :

- les dégustateurs ;
- les variables, c'est-à-dire les mélanges.

C'est une représentation très utile pour relier les groupes de dégustateurs aux mélanges qu'ils préfèrent.

Dans JMP, si le biplot est disponible :

1. afficher le biplot de l'ACP ;
2. repérer les groupes de dégustateurs ;
3. observer dans quelles directions se trouvent les mélanges ;
4. associer chaque groupe de dégustateurs aux mélanges situés dans la même zone du graphique.

On pourra écrire des interprétations du type :

- les dégustateurs situés dans la direction de M_3 apprécient davantage la formulation fortement mentholée ;
- les dégustateurs situés dans la direction de M_2 apprécient davantage les formulations sucrées ;
- les dégustateurs proches du centre du graphique ont des préférences moins marquées ou plus équilibrées.

Sauvegarde des coordonnées ACP

Pour poursuivre l'analyse, il est utile de sauvegarder les coordonnées des dégustateurs sur les premières composantes principales.

Dans JMP, à partir de la fenêtre de résultats de l'ACP :

1. ouvrir le menu associé au rapport de l'ACP, souvent accessible par le triangle rouge ;
2. choisir une option du type :

Enregistrer les composantes

ou

Save Principal Components.

JMP ajoute alors à la table de données de nouvelles colonnes, par exemple :

PC1, PC2, PC3.

Ces coordonnées pourront être utilisées :

- pour colorer les dégustateurs ;
- pour effectuer une classification ;
- pour trier les lignes d'une carte thermique ;
- pour construire un rapport plus lisible.

Regroupement des dégustateurs

La carte ACP permet souvent de voir apparaître des groupes de dégustateurs. Pour rendre ce regroupement plus objectif, on peut réaliser une classification.

L'idée est de regrouper les dégustateurs ayant des profils de notes proches.

On peut effectuer la classification :

- directement sur les notes normalisées ;
- ou sur les premières coordonnées ACP, par exemple PC1 et PC2.

Dans JMP :

1. aller dans :

Analyse → Clustering → Classification hiérarchique,

ou une option équivalente selon la version ;

2. utiliser comme variables :

PC1, PC2

ou bien les notes normalisées

M1_norm, ..., M7_norm;

3. choisir une distance euclidienne ;

4. choisir une méthode de regroupement, par exemple la méthode de Ward si elle est disponible ;
5. observer le dendrogramme ;
6. choisir un nombre raisonnable de groupes, par exemple 2, 3 ou 4.

On peut ensuite créer une nouvelle colonne :

Groupe

indiquant le groupe attribué à chaque dégustateur.

Coloration de la carte ACP par groupes

Une fois les groupes de dégustateurs créés, on peut retourner sur la carte ACP et colorer les points selon la colonne Groupe.

Dans JMP :

1. revenir à la table de données ;
2. sélectionner la colonne Groupe ;
3. choisir :

Lignes → Couleur ou marque par colonne;

4. revenir sur le graphique ACP.

Les dégustateurs appartenant au même groupe apparaissent alors avec la même couleur.

On peut ainsi vérifier si les groupes statistiques correspondent à des zones cohérentes sur la carte ACP.

Carte thermique triée par groupes

La carte thermique brute peut être difficile à lire si les dégustateurs sont placés dans un ordre arbitraire. Une fois les groupes identifiés, on peut trier la table par groupe pour faire apparaître des blocs de préférences.

Dans JMP :

1. trier la table selon la colonne Groupe ;
2. refaire la carte thermique des notes ;
3. placer les dégustateurs en lignes ;
4. placer les mélanges en colonnes ;
5. utiliser la note comme couleur.

La carte thermique triée par groupes permet de visualiser plus clairement les profils typiques :

- groupe appréciant les mélanges sucrés ;
- groupe appréciant les mélanges mentholés ;
- groupe préférant les formulations équilibrées ;
- groupe rejetant fortement un type de formulation.

Caractérisation des groupes

Pour interpréter les groupes de dégustateurs, on calcule pour chaque groupe la note moyenne attribuée à chaque mélange.

Si g désigne un groupe de dégustateurs, on définit :

$$\bar{Y}_{g,M_j} = \frac{1}{n_g} \sum_{i \in g} Y_{i,M_j},$$

où n_g est le nombre de dégustateurs du groupe.

On obtient une table du type :

Groupe	M_1	M_2	M_3	M_4	M_5	M_6	M_7
G_1	...	...	...	...	...	...	...
G_2	...	...	...	...	...	...	...
G_3	...	...	...	...	...	...	...

Cette table permet de caractériser chaque groupe :

- quel mélange est préféré par le groupe ?
- quel mélange est rejeté ?
- le groupe préfère-t-il les mélanges sucrés, citronnés, mentholés ou équilibrés ?

On peut alors proposer des profils de groupes, par exemple :

- groupe 1 : amateurs de citronnade sucrée classique ;
- groupe 2 : amateurs de menthe forte ;
- groupe 3 : amateurs de compromis équilibrés ;
- groupe 4 : dégustateurs rejetant fortement la menthe.

Retour vers la formulation

L'analyse globale du plan de mélange permettait de rechercher une formulation optimale moyenne. L'ACP montre que cette formulation moyenne peut ne pas correspondre aux préférences de tous les dégustateurs.

Pour chaque groupe identifié, on peut déterminer :

- le mélange testé le plus apprécié ;
- le mélange testé le moins apprécié ;
- la zone du triangle de formulation qui semble la plus favorable.

On peut alors discuter l'idée suivante :

un produit optimal dépend de la cible de dégustateurs visée.

Par exemple, une formulation contenant beaucoup de menthe peut avoir une note moyenne faible, mais être très appréciée par un groupe particulier. Inversement, une formulation équilibrée peut être moins clivante et mieux adaptée à un public large.

Travail à réaliser

1. Construire la table finale des notes par formulation réelle :

$$M_1, \dots, M_7.$$

2. Normaliser éventuellement les notes de chaque dégustateur.
3. Réaliser l'ACP dans JMP.
4. Relever la part de variance expliquée par PC1, PC2 et PC1+PC2.
5. Interpréter la carte des dégustateurs.
6. Interpréter la représentation des variables.
7. Identifier les mélanges qui structurent le plus les préférences.
8. Réaliser un regroupement des dégustateurs.
9. Colorer la carte ACP selon les groupes obtenus.
10. Refaire une carte thermique en triant les dégustateurs par groupe.
11. Caractériser chaque groupe par ses mélanges préférés et rejetés.
12. Conclure sur l'intérêt de l'ACP pour la formulation d'un produit destiné à des cibles différentes.